

大模型长度外推

详解基于调整RoPE旋转角度的大模型长度外推方法

红雨瓢泼 中山大学 计算机技术硕士

关注他

92 人赞同了该文章

目录

收起

- 一、前言
- 二、RoPE知识回顾
 - 2.1 RoPE的基本原理
 - 2.2 周期性
 - 2.3 远端衰减性
- 三、大模型长度扩展方法
 - 3.1 Position Interpolation
 - 3.2 NTK-Aware Interpolation
 - 3.3 NTK-by-parts Interpolati...
 - 3.4 Dynamic NTK Interpolat...
 - 3.5 YaRN
- 四、总结


详解基于调整RoPE旋转角度的大模型长度外推方法

mp.weixin.qq.com/s/RtI95hu-ZLxGkdGuNI...

大模型长度外推

一、前言

旋转位置编码RoPE (Rotary Position Embedding) 被广泛应用于目前的大模型中，包括但不限于 Llama、Baichuan、ChatGLM、Qwen等。但RoPE却有着较弱的长度外推性，也就是在推理时，当模型的输入长度超出训练长度时，模型的性能会急剧下降，具体表现为困惑度的急剧上升。如下图所示，我们评测了LLaMA2-7B在不同输入长度中的困惑度，当评测长度为8192时，模型的困惑度急剧上升。



于是涌现出了一系列基于RoPE的大模型长度扩展的工作，并且取得了非常优秀的效果。在本文中，我们将对这些方法进行介绍，包括线性插值、NTK-Aware插值、NTK-by-parts、Dynamic NTK、YaRN等。上述方法均通过减小RoPE的旋转弧度来进行长度扩展，若读者对RoPE的基本原理尚未熟悉，建议先阅读文章：

图解RoPE旋转位置编码及其特性

mp.weixin.qq.com/s/-LxVXjoM0imXMC7DK...



二、RoPE知识回顾

磨刀不误砍柴工，我们先回顾RoPE的一些原理和特性，以便后续对各种长度扩展方法的理解。


2.1 RoPE的基本原理

在RoPE旋转位置编码中，存在位置编码函数 $q_m = f(q, m) = R_m q$ ，该函数表示对任意词向量 q 添加绝对位置信息 m ，得到 q_m ，其中 R_m 是一个矩阵，可以形象地把 R_m 理解为一个旋转矩阵。最终 $f(q, m)$ 如下公式所示：

$$\begin{pmatrix} \cos m\theta_0 & -\sin m\theta_0 & 0 & 0 & \cdots & 0 & 0 \\ \sin m\theta_0 & \cos m\theta_0 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & \cos m\theta_1 & -\sin m\theta_1 & \cdots & 0 & 0 \\ 0 & 0 & \sin m\theta_1 & \cos m\theta_1 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & \cos m\theta_{d/2-1} & -\sin m\theta_{d/2-1} \\ 0 & 0 & 0 & 0 & \cdots & \sin m\theta_{d/2-1} & \cos m\theta_{d/2-1} \end{pmatrix} \begin{pmatrix} q_0 \\ q_1 \\ q_2 \\ q_3 \\ \vdots \\ q_{d-2} \\ q_{d-1} \end{pmatrix}$$


我们可以以向量分组旋转的方式来理解上面的位置编码函数，它表示将向量 q 中的 d 个分量划分成 $d/2$ 个分组，每组分量视为一个二维向量，分别旋转。当向量 q 位于位置 m 时，只需要将它的第 i 组分量旋转 $m\theta_i = m * base^{-2i/d}$ ，就可以得到赋予了位置信息 m 的 q_m ，其中 d 表示向量维度，在LLaMA中， $base = 10000$ 。

我们以向量 q 的第0组分量 (q_0, q_1) 为例，假设 $(q_0, q_1) = (1, 0)$ ，此时 $i = 0$ ，则 $m\theta_i = m$ 。当 (q_0, q_1) 位于位置0,1,2,3时，分别对应将 (q_0, q_1) 旋转0,1,2,3弧度。其它组分量的旋转弧度，可以依此类推。




2.2 周期性

下图展示了每组分量的旋转弧度和它所处位置的关系。对于每组分量，它的旋转弧度随着位置索引的增加而线性增加。每组分量的旋转都具有周期性，因为旋转一圈的弧度是 2π ，所以RoPE中的向量旋转就像时钟一样，具有周期性。并且我们发现越靠后的分组，它的旋转速度越慢。例如当向量位于位置500时，它的第0组分量已经旋转了500弧度，但第8组分量的旋转弧度仅为158左右。




下图展示了上述旋转弧度所对应的正弦函数。我们可以更直观地看到，越靠后的分组，它的旋转速度越慢，正弦函数的周期越大、频率越低。



2.3 远程衰减性

在此前的文章中，我们已经详细介绍了RoPE的远程衰减特性，具体表现为：对于两个词向量，若它们之间的距离越近，则它们的内积分数越高，反之则越低。随机初始化两个向量q和k，将q固定在位置0上，k的位置从0开始逐步变大，依次计算q和k之间的内积。随着q和k的相对距离的增加，它们之间的内积分数呈现出远程衰减的性质。



三、大模型长度扩展方法

基于RoPE的大模型进行长度扩展的方法，大致可以分为两大类：【局部注意力】与【调整旋转弧度】。本文主要讨论基于调整旋转弧度的长度扩展方法。

在此，请大家记住：任意向量 q 位于位置 m 时，它的第 i 组分量的旋转弧度为 $m\theta_i = m * base^{-2i/d}$ ，其中 d 表示向量 q 的维度。我们后续讨论的所有长度扩展方法，本质上都是通过缩小旋转弧度 $m\theta_i$ ，以达到长度扩展的目的。

注意：如未特殊说明，本文后续的所有方法讨论均建立在不进行微调的前提下。


3.1 Position Interpolation

当推理长度超出RoPE的训练长度 L 时，为什么模型的性能会下降？在RoPE中，每个位置 m 都对应一个旋转弧度 $m\theta_i$ ，当模型的训练长度为 L 时，位置0到位置 $L - 1$ 对应的旋转弧度范围为 $[0, (L - 1)\theta_i]$ 。

按照炼丹经验，我们可以合理地猜想：模型在训练时，只见过 $[0, (L - 1)\theta_i]$ 范围内的旋转弧度，未见过大于 $(L - 1)\theta_i$ 的旋转弧度，所以当推理长度大于 L 时，模型难以理解新的旋转弧度，无法正确注入位置信息，导致模型性能下降。

当然，真实原因比上述猜想更加复杂，此处我们只是希望以一种更加直观的猜想引出Position Interpolation，更具体的分析可以参考后续章节。

对于上述猜想，我们举个例子，LLaMA的训练长度为2048，如下图所示，对于第0组分量，训练时模型见过的旋转弧度范围为 $[0, 2047]$ ，当LLaMA在4096的长度上进行推理时，由于它在训练时未见过 $[2048, 4095]$ 的旋转弧度，所以难以理解，造成模型的性能下降。




基于上述猜想，我们可以认为模型已经能够非常好地理解旋转弧度范围 $[0, (L-1)\theta_i]$ 所表示的位置信息，那么是否存在某种方法，可以使用旋转弧度范围 $[0, (L-1)\theta_i]$ 来表示更长的长度范围 $[0, L'-1]$ 呢？


Position Interpolation的做法简单且直观：缩小每个位置的旋转弧度，让向量旋转得慢一些，每个位置的旋转弧度变为原来的 $\frac{L}{L'}$ ，长度扩大几倍，则旋转弧度缩小几倍。最终，经过调整后，位置的旋转弧度如下公式所示：

$$\frac{mL\theta_i}{L'} = \frac{mL}{L'} base^{-2i/d}$$

举个例子，我们设 $L = 2048, L' = 4096$ ，也就是将模型的长度从2048扩展至4096，Position Interpolation将每个位置的旋转弧度均变为原来的一半。下图直观地展示了第0组分量的旋转弧度的变化情况，原来 $[0, 2047]$ 的旋转弧度范围就可以用来表示4096的长度范围。这相当于在原来的弧度范围内，插入更多的位置，由于旋转弧度是线性变化的，所以也称为线性位置插值。



下图展示了第0组分量的旋转弧度所对应的正弦函数的变化情况。进行位置插值后，向量旋转速度变慢，周期变大，频率变慢。



NTK-Aware Interpolation以NTK（神经正切核）作为理论支撑，或者说灵感来源。作者认为高频信息对于神经网络非常重要，而Position Interpolation对于向量的所有分组不加区分地缩小旋转弧度，降低旋转速度（进一步体现为对其正弦函数进行拉伸），会导致模型的高频信息缺失，从而影响模型的性能。


在前文中我们介绍过，位置越靠前的向量分组，旋转速度越快，频率越高，作者希望保留这些高频信息。在NTK-Aware插值中，经过调整后，位置 m 的旋转弧度如下公式所示，其中LLaMA中的 $base$ 为10000， α 表示的缩放因子：

$$m\theta_i = m * (base * \alpha)^{-2i/d} = m * (10000 * \alpha)^{-2i/d}$$


我们以Code LLaMA为例进行分析，Code LLaMA中 $\alpha = 100$ ，也就是将原始模型的 $base$ 放大100倍。调整后的旋转弧度与原始旋转弧度的倍数关系如下：

$$\frac{m * (1000000)^{-2i/d}}{m * (10000 * \alpha)^{-2i/d}} = 100^{-2i/d}$$


如下图所示，越靠后的分组，旋转弧度缩小的倍数越大。其中第0分组的旋转弧度保持不变，最后一个分组的旋转弧度变为原来的1/100。可以将NTK-Aware Interpolation的思想总结为：保留高频信息；高频分量旋转速度降幅低，低频分量旋转速度降幅高；在高频部分进行外推，低频部分进行内插。



评测结果表明，在不进行finetune的时候，NTK-Aware插值的效果比线性插值更优。



为什么NTK-Aware Interpolation能够奏效？作者以NTK的理论进行解释。但我们认为从旋转周期的角度也许可以进行更加直观且合理的解释。前文中我们介绍过，位置越靠后的分组的旋转速度越慢，频率越低，周期越长。如下图所示，对于第0组分量，仅在位置7时，就已经旋转一周。但对于第64组分量，当位置为2047时，其旋转弧度约为0.2047，甚至仍未完成1/4周旋转。



我们可以将NTK-Aware Interpolation奏效的原因按照如下方式进行解释：

1. 靠前的分组，在训练中见过非常多完整的旋转周期，位置信息得到了充分的训练，所以具有较强的外推能力。
2. 靠后的分组，在训练中无法见到完整的旋转周期，或者见到的旋转周期非常少，训练不够充分，外推性能弱，需要进行位置插值。

3.3 NTK-by-parts Interpolation

NTK-by-parts Interpolation则是基于NTK-Aware Interpolation进行优化，其核心思想是：**不改变高频部分，仅缩小低频部分的旋转弧度**。也就是不改变靠前分组的旋转弧度，仅减小靠后分组的旋转弧度，这就是by-parts的含义。

第 i 个分组的旋转周期如下：

$$\lambda_i = \frac{2\pi}{\theta_i} = 2\pi * base^{2i/d}$$

第 i 个分组在训练长度内旋转的周期个数如下：

$$r(i) = \frac{L}{\lambda_i}$$


以每组分量在训练长度内旋转的周期个数 $r(i)$ 分类讨论插值方案。引入超参数 β ，表示旋转周期个数的约束条件。

1. $r(i) \geq \beta$ ：旋转周期数量足够多，则认为该分组为高频部分，无需改变。
2. $r(i) < \beta$ ：旋转周期数量少，则为低频分组，进行Position Interpolation。

当然，在NTK-by-parts Interpolation的实现中，分类讨论比上述描述稍微复杂一点。上述方法进行了相应的简化，但思想是一致的。

3.4 Dynamic NTK Interpolation

当超出训练长度时，上述插值方法都比原模型直接外推的效果更好，但是它们都有一个共同的缺点，在训练长度内，推理表现都比原模型差。如下图，灰色表示LLaMA直接外推的表现，在2048长度内，原始模型的困惑度显著低于各种插值方法。



Dynamic NTK Interpolation是一种动态插值的方法，思路也很简单：**推理长度小于等于训练长度时，不进行插值；推理长度大于训练长度时，每一步都通过NTK-Aware Interpolation动态放大base。**

l 表示当前的序列长度， L 表示模型训练长度，当 $l \leq L$ 时，不改变模型原始的旋转弧度；当 $l > L$ 时，使用NTK-Aware Interpolation调整旋转弧度为 $m * (base * \alpha)^{-2i/d}$ ， $\alpha = (\frac{l}{L})^{d/(d-2)}$ 。注意，每生成一个token后， l 都会加1，当 $l > L$ 时，每一次生成都会根据


3.5 YaRN

前文中我们介绍过，无论是Position Interpolation还是NTK类方法，本质都是通过减小旋转弧度，降低旋转速度，来达到长度扩展的目的。这将导致位置之间的旋转弧度差距变小，词向量之间的距离变得比原来更近，词向量之间的点乘变大，破坏模型原始的注意力分布。所以经过插值之后，模型在原来的训练长度内的困惑度均有所提升，性能受损。

向量的内积公式如下。向量旋转不改变模长，当 q 和 k 的旋转弧度变小，导致它们之间的夹角 γ 变小，所以两者的内积会变大，最终会改变模型的注意力分布。

$$q \cdot k = |q| * |k| * \cos(\gamma)$$

我们以图像的方式进一步分析注意力分布变化的问题。初始化两个全一向量 q 和 k ，将 q 固定在位置0上， k 的位置从0开始逐步变大，依次计算 q 和 k 之间的内积。对于不同的长度扩展策略， q 和 k 的内积变化如下图。无论是NTK还是线性插值，相对距离固定时， q 和 k 之间的内积分数都将变大，进而导致模型的注意力分布改变。并且可以发现，RoPE的注意力远程衰减的性质变弱，这也导致整个序列的注意力分布变得更加平滑。



YaRN本质上是NTK-by-parts Interpolation与注意力分布修正策略的结合，仅缩小低频部分的旋转弧度，且通过温度系数修正注意力分布。只需将原来的注意力分数除以温度 t 即可。

$$\frac{q_m^T k_n}{\sqrt{|d|}} \rightarrow \frac{q_m^T k_n}{t\sqrt{|d|}}, \quad \sqrt{\frac{1}{t}} = 0.1 * \ln\left(\frac{L'}{L}\right) + 1$$

我们以LLaMA为例，当长度从2048扩展至16384时，长度扩展为原来的8倍，代入公式，计算得到 $t=0.6853$ 。回顾温度系数对注意力分布的影响，当 t 变大，注意力分布更加平滑，方差更小；当 t 变小，注意力分布更加尖锐，区分度变大，方差变大。 $t=0.6853$ 意味着缓解注意力分布过于平滑的问题，让注意力分布方差更大些。

下图是未经过微调的动态插值方法的比较，修正了注意力分布的Dynamic-YaRN，显著优于未修正注意力分布的Dynamic-PI方法。




Figure 5: The comparison between RoPE, Dynamic-PI and Dynamic-YaRN using Llama 2 on a long GovReport sample. This model has not been finetuned for long context.

四、总结

本文介绍的大模型长度扩展方法，本质上都是通过缩小RoPE的旋转弧度，降低旋转速度，从而达到扩展长度的目的，并且通过不断优化缩小旋转弧度的方案，以提升模型的性能。

调整旋转弧度后，将对模型的注意力分布产生影响，如要达到更优的效果，一般还需要使用少量长文本进行微调，让模型适应调整后的位置信息。

一句话总结各种方法的特点：

1. Position Interpolation：目标长度是原来的 n 倍，则旋转弧度减小至原来的 $1/n$ 。
2. NTK-Aware Interpolation：增大RoPE的base，保留高频信息；高频分量旋转速度降低，低频分量旋转速度升高；在高频部分进行外推，低频部分进行内插。
3. NTK-by-parts Interpolation：不改变高频部分，仅缩小低频部分的旋转弧度。

4. Dynamic NTK Interpolation: 推理长度小于等于训练长度时，不进行插值；推理长度大于训练长度时，每一步都通过NTK-Aware插值动态放大base。
5. YaRN: NTK-by-parts Interpolation与注意力分布修正策略的结合，通过温度系数修正注意力分布。

发布于 2023-12-06 08:25 · IP 属地广东

[外推](#) [大模型](#) [LLM](#)



欢迎参与讨论

7 条评论

默认 最新



JoeYang

言简意赅👍

14 小时前 · IP 属地北京

回复 喜欢



xinxinxinxin

醍醐灌顶，感谢作者的优质文章

05-10 · IP 属地北京

回复 喜欢



RENNY

牛👍

02-26 · IP 属地浙江

回复 喜欢



刘玉梁

作者写的真棒！
一点小疑问，在NTK-aware方法中，对于 α 是否缺少了一个 $(\dim/(\dim-2))$ 的缩放因子呢，参见reddit上原作者的代码colab.research.google.com...

02-20 · IP 属地美国

回复 喜欢



haoyunyouyou

我以为怎么得是博士生的文章吧，一看竟然是硕士，肃然起敬

2023-12-28 · IP 属地湖北

回复 喜欢



董际成

clear

2023-12-26 · IP 属地北京

回复 喜欢



Semeron

清晰易懂，博主厉害👍

2023-12-13 · IP 属地北京

回复 喜欢

文章被以下专栏收录



xinxinxinxin

推荐阅读

大模型长度外推技术

参考资料：Transformer升级之路：16、“复盘”长度外推技术 - 科学空间|Scientific Spaces 问题定义：免训练长度外推，就是不需要用长序列数据进行额外的训练，只用短序列语料对模型进行训…

清风徐来

发表于大模型原理…

大模型外推 | 外推方法

背景 预训练模型通常只具备4k的上下文长度，这阻碍了模型能够处理的输入长度，从而影响模型在长下文场景下的应用能力。现有的研究表明当模型处理的长度超过预训练的上下文长度时，模型的PPL…

辰星

支撑钢框架的ABAQUS建模技巧与注意事项

本文对一个两层中心支撑钢框架进行ABAQUS建模，希望建模过程和所提到的注意事项能对相关方面的初学者有借鉴意义。支撑框架选取Uriz和Mahin[1]试验报告中的中心支撑钢框架进行模拟，结构布…

Sebastian Lou

大模型对齐 | KTO对齐

KTO: Model Alignment as Prospect Theoretic Optimization 背景 RLHF和DPO方法已经被证明比SFT有更好的效果。但是，RLHF和DPO都使用偏好数据作为输入。为了理解这些方法为什么有效，以…

辰星

